



Proyecto Deep Learning, Informe #1

Santiago Rivera Montoya
Santiago Alexander Losada
Emanuel López Higueta

Deep Learning, Facultad de Ingeniería, Universidad de Antioquia Abril 2023

1. Introducción

El consumo energético a nivel global está en constante cambio, impulsado por factores económicos, sociales y ambientales. Las predicciones precisas del consumo de energía son esenciales para la planificación de recursos y el desarrollo sostenible. Con este propósito, el modelo propuesto utilizará técnicas avanzadas de Machine Learning (ML), específicamente redes neuronales LSTM (Long Short-Term Memory), para predecir el consumo futuro de energía de varios países. El modelo se entrenará utilizando datos históricos de consumo, producción, importación y exportación de energía, considerando las variaciones y particularidades de cada país. Con la capacidad de analizar y generalizar patrones a nivel global, el modelo permitirá anticipar los cambios en las necesidades energéticas de diversas regiones, ofreciendo herramientas clave para la toma de decisiones estratégicas en políticas energéticas y el desarrollo de infraestructuras sostenibles.

2. Dataset

A través del dataset [World Energy Consumption](#) en Kaggle, se ha puesto a disposición un conjunto de datos globales sobre el consumo de energía. Este dataset incluye registros históricos de consumo energético, producción, importaciones y exportaciones de energía para varios países desde 1965 hasta 2021.

En total cuenta con 22012 filas y 129 columnas, contiene datos de consumo de energía en múltiples regiones, permitiendo la creación de modelos predictivos que consideren las variaciones en las necesidades energéticas de cada país. Algunas de las variables claves del conjunto de datos incluyen:

- Consumo total de energía
- Producción de energía
- Importación y exportación de energía
- Población
- Año
- País y región

3. Métricas

En este proyecto de predicción de consumo energético utilizando modelos LSTM, se emplearán métricas tanto de desempeño técnico como de impacto en el negocio para evaluar la efectividad de los resultados.

Desde el punto de vista técnico, se utilizarán principalmente las siguientes métricas:

- El **Mean Absolute Error (MAE)** mide el error promedio absoluto entre las predicciones y los valores reales, expresado en las mismas unidades del consumo energético. Permite interpretar directamente cuánto, en promedio, se equivoca el modelo por año o por país.
- El **Root Mean Squared Error (RMSE)** proporciona una medida de error que penaliza más fuertemente los errores grandes, ofreciendo una perspectiva más sensible a desviaciones importantes.

Adicionalmente, se consideran métricas orientadas al impacto de negocio, que reflejan el valor práctico de la solución:

- **Ahorro de costos energéticos:** Una predicción más precisa permite planificar mejor la generación, importación o almacenamiento de energía, reduciendo costos operativos.
- **Precisión en la planificación de infraestructura:** Con proyecciones confiables, se pueden optimizar las decisiones sobre inversiones en nuevas plantas, redes de distribución o fuentes renovables.

En conjunto, estas métricas garantizan no solo la evaluación cuantitativa del modelo, sino también su relevancia y utilidad para resolver problemas reales en el sector energético.

4. Referencias y resultados previos

1. Hyndman, R. J., & Athanasopoulos, G. (2018). Forecasting: principles and practice.
2. Chakraborty, P., & Sahoo, A. (2018). Energy consumption forecasting using machine learning algorithms: A review. *Energy Reports*, 4, 52-64.
3. Zhao, Z., & Zhang, L. (2019). Deep learning for energy consumption prediction and optimization. *Energy and Buildings*, 199, 47-58.
4. Li, G., & Li, X. (2020). Prediction of electricity consumption based on LSTM neural network. *Journal of Electrical Engineering & Technology*, 15(2), 765-772.
5. Zhang, X., & Li, Y. (2021). Short-term energy consumption forecasting using machine learning models: A comparative study. *Energy*, 214, 118674.